

PYTHON • DATA ANALYSIS

Обработка и анализ данных о заявках

Очистка набора данных, расчёт показателей и визуализация результатов

Python • pandas • matplotlib • проверка качества

Автор портфолио: Леонид (ExpertStudy)

31 августа 2026 • Все данные и сценарии вымышлены

ДЕМОНСТРАЦИОННАЯ УЧЕБНАЯ РАБОТА • НЕ КЛИЕНТСКИЙ ЗАКАЗ

Содержание и паспорт работы

Краткая навигация по демонстрационному материалу.

- 01 Постановка задачи
- 02 Данные и методика
- 03 Реализация на Python
- 04 Результаты анализа
- 05 Проверка качества и выводы

Паспорт работы

Формат	Краткий технический отчёт с фрагментами кода
Набор данных	Синтетические заявки за 8 недель, 120 исходных строк
Инструменты	Python 3.11+, pandas, matplotlib
Результат	Очищенная выборка, KPI, разрез по каналам, рекомендации

Статус Материал создан как самостоятельный учебный пример для портфолио. Он показывает подход, стиль объяснения и уровень оформления; реальные заказчики и их данные не использовались.

01 Постановка задачи

Учебный сценарий: аналитика входящих заявок образовательного сервиса.

В распоряжении аналитика находится выгрузка заявок из CRM. Руководителю нужны понятные показатели: объём, выручка, средний чек, доля завершённых заявок и сравнение каналов привлечения. В исходной таблице намеренно заложены типичные дефекты качества данных.

Цели работы

- проверить структуру файла, типы данных, пропуски и дубликаты;
- нормализовать названия категорий и обработать пропуски без потери логики;
- рассчитать ключевые показатели и сравнить каналы привлечения;
- сформулировать выводы и ограничения анализа понятным языком.

Состав полей

Поле	Тип	Назначение
order_id	integer	Уникальный номер заявки
created_at	date	Дата создания
channel	category	Канал привлечения
region	category	Регион пользователя
amount_kzt	decimal	Сумма заявки, тенге
processing_min	float	Время обработки, минуты
status	category	completed / in_progress / cancelled

Граница примера Значения синтетические. Работа демонстрирует метод и оформление, а не описывает деятельность реальной компании.

02 Данные и методика

Последовательность обработки выбрана так, чтобы каждый шаг можно было воспроизвести.

Шаг	Проверка	Решение
1	Дубликаты по order_id	Оставить первую запись; 2 строки исключить
2	Сумма <= 0	Считать ошибкой и исключить из расчёта выручки
3	Пропуск processing_min	Заполнить медианой внутри канала
4	Разный регистр channel	strip + lower + словарь соответствий
5	Неверный status	Проверить по допустимому множеству

Почему используется медиана

Время обработки имеет длинный правый хвост: отдельные заявки могут ожидать ответа несколько часов. Медиана менее чувствительна к таким выбросам, поэтому лучше отражает типичное значение внутри канала.

Контрольные критерии

- после очистки order_id уникален и не содержит пропусков;
- amount_kzt положителен для всех строк, участвующих в расчётах;
- даты преобразованы в datetime, категории - в единый справочник;
- агрегаты по каналам в сумме совпадают с общими итогами.

Воспроизводимость Очистка оформлена как функция: входная таблица не изменяется, а результат можно повторно получить на новой выгрузке.

03 Реализация на Python

Ключевые фрагменты кода: загрузка, очистка и расчёт агрегатов.

Листинг 1. Функция очистки

```
import pandas as pd

ALLOWED_STATUS = {"completed", "in_progress", "cancelled"}
CHANNEL_MAP = {
    "web": "Веб-форма",
    "marketplace": "Маркетплейс",
    "partners": "Партнёры",
    "repeat": "Повторные",
}

def clean_orders(source: pd.DataFrame) -> pd.DataFrame:
    df = source.copy()
    df.columns = df.columns.str.strip().str.lower()
    df = df.drop_duplicates(subset="order_id", keep="first")
    df["created_at"] = pd.to_datetime(df["created_at"], errors="coerce")
    df["channel"] = (df["channel"].astype("string")
                    .str.strip().str.lower().map(CHANNEL_MAP))
    df["amount_kzt"] = pd.to_numeric(df["amount_kzt"], errors="coerce")
    df["processing_min"] = pd.to_numeric(df["processing_min"], errors="coerce")
    if df["channel"].isna().any():
        raise ValueError("Обнаружен неизвестный канал")
    df = df[df["amount_kzt"].gt(0) & df["created_at"].notna()]

    medians = df.groupby("channel")["processing_min"].transform("median")
    df["processing_min"] = df["processing_min"].fillna(medians)
    if not set(df["status"]).dropna().issubset(ALLOWED_STATUS):
        raise ValueError("Обнаружен неизвестный статус")
    return df
```

Листинг 2. Расчёт KPI и группировка

```
orders = clean_orders(pd.read_csv("orders_demo.csv"))

kpi = {
    "orders": orders["order_id"].nunique(),
    "revenue_kzt": orders["amount_kzt"].sum(),
    "average_check_kzt": orders["amount_kzt"].mean(),
    "completion_rate": orders["status"].eq("completed").mean(),
    "median_processing_min": orders["processing_min"].median(),
}

by_channel = (orders.groupby("channel", as_index=False)
               .agg(orders=("order_id", "nunique"),
                    revenue_kzt=("amount_kzt", "sum"),
                    average_check_kzt=("amount_kzt", "mean"))
               .sort_values("revenue_kzt", ascending=False))
```

04 Результаты анализа

Итоги рассчитаны на 118 корректных уникальных заявках.

Показатель	Значение	Интерпретация
Заявки	118	После удаления двух дубликатов
Выручка	3 591 000 ₸	Сумма положительных amount_kzt
Средний чек	30 432 ₸	Выручка / число заявок
Завершено	81,4%	96 заявок со status = completed
Медиана обработки	73 мин	Типичное время до первичного решения

Выручка по каналам

Синтетический набор данных · млн тенге




Рисунок 1. Выручка по каналам на синтетическом наборе данных

Канал	Заявки	Выручка	Средний чек
Веб-форма	42	1 260 000 ₸	30 000 ₸
Маркетплейс	35	945 000 ₸	27 000 ₸
Партнёры	23	828 000 ₸	36 000 ₸
Повторные	18	558 000 ₸	31 000 ₸

05 Проверка качества и выводы

Финальная часть отделяет проверенные факты от предположений.

Листинг 3. Минимальные автоматические проверки

```
assert orders["order_id"].is_unique
assert orders["amount_kzt"].gt(0).all()
assert orders["processing_min"].notna().all()
assert abs(by_channel["revenue_kzt"].sum()
          - orders["amount_kzt"].sum()) < 0.01
```

Выводы

- веб-форма даёт наибольший объём и максимальную выручку - 35,1% общего результата;
- партнёрский канал имеет самый высокий средний чек: 36 000 ₸;
- маркетплейс обеспечивает заметный поток, но средний чек ниже общего на 11,3%;
- медианное время обработки 73 минуты можно использовать как базовую линию для SLA.

Практические рекомендации

1. сохранить веб-форму как основной канал и проверить её конверсию по неделям;
2. для партнёрского канала отдельно отслеживать стоимость привлечения;
3. разделить processing_min по типу заявки и приоритету;
4. перед управленческими выводами добавить расходы и фактическую маржу.

Ограничение Синтетический набор мал и не подходит для причинных выводов. В реальном проекте потребуются словарь данных, журнал изменений и контроль полноты выгрузки.